上海科技大学
ShanghaiTech University

本科毕业论文（设计）

题　　目：同态感知：子空间并集的拓展、稀疏信号恢复与概率分析

学生姓名：汪博石

学　　号：18926396

入学年份：2016

所在学院：信息科学与技术学院

攻读专业：计算机科学与技术

指导教师：Manolis C. Tsakiris

上海科技大学

2020 年 05 月

上海科技大学
ShanghaiTech University

THESIS

Subject: Homomorphic Sensing: Extension to Union of Subspaces Case, Sparse Signal Recovery and Probabilistic Analysis

Student Name: Boshi Wang

Student ID : 18926396

Year of Entrance: 2016

School: School of Information Science and Technoology

Major: Computer Science and Technology

Advisor: Manolis C. Tsakiris

ShanghaiTech University

Date: 05/2020

上海科技大学

毕业论文(设计)学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名：汪博石

日期： 2020 年 5 月 23 日

上海科技大学

毕业论文（设计）版权使用授权书

本毕业论文（设计）作者同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海科技大学可以将本毕业论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本毕业论文（设计）。

保　密□，在___年解密后适用本授权书。

本论文属于

不保密☑。

（请在以上方框内打“√”）

作者签名：汪博石　　指导教师签名：

日期：2020年5月24日　　日期：2020年5月26日

摘 要

同态感知（Homomorphic Sensing）研究能够保证从某一信号在一有限线性变换集合中的映射下的同态像唯一恢复原信号的条件。这一问题在诸多数据科学和工程领域出现的问题有所应用，例如记录连结（record linkage）和图像配准（image registration）等。在这篇论文中，我们对同态感知做出两方面的贡献。首先，我们将同态感知的输入空间由单一线性空间拓展至多个线性空间的并集。这一工作的应用之一是一类稀疏信号恢复唯一性的问题。其次，我们研究噪声下的同态感知，并且推导可以刻画信噪比（signal-to-noise ratio）与一个自然的信号估计器的估计误差之间关系的决定性和概率性的结论。

关键词： 同态感知，乱序线性回归，无标感知，实相位恢复，稀疏信号恢复，代数几何

Abstract

Homomorphic Sensing studies conditions which guarantee unique recovery of a signal from its homomorphic image under some unknown transformation in a finite set. It finds applications in many problems which arise in data science/engineering such as record linkage and image registration. In this thesis we contribute to Homomorphic Sensing in two aspects. Firstly, we extend Homomorphic Sensing to the case where the input space is a *union* of linear subspaces. One of the applications of this work is in uniqueness guarantees for a class of sparse signal recovery problems. Secondly, we study Homomorphic Sensing under noise, and develop both deterministic and probabilistic results which characterize the relation of the signal-to-noise ratio and the estimation error of a natural estimator of the original signal.

Keywords: Homomorphic Sensing, Linear Regression without Correspondence, Unlabelled Sensing, Real Phase Retrieval, Sparse Signal Recoveries, Algebraic Geometry

目 录

第 1 章 同态感知：背景 ····· 1
1.1 同态感知和其实例 ····· 1
1.2 论文贡献与结构 ····· 2
1.3 符号惯例与背景知识 ····· 3
第 2 章 多个子空间并集的同态感知 ····· 5
2.1 可逆变换下的感知 ····· 5
2.2 任意变换 ····· 7
2.3 稀疏信号恢复 ····· 10
第 3 章 噪声下的同态感知 ····· 14
3.1 模型与相关假设 ····· 14
3.2 决定性分析 ····· 14
3.3 概率性分析 ····· 16
3.3.1 降维至一维情形 ····· 17
3.3.2 进一步的放缩（满秩情形） ····· 19
3.3.3 对随机投影进行概率约束 ····· 20
3.3.4 约束估测误差 ····· 21
3.3.5 主要结论与渐近分析 ····· 21
3.3.6 对于一般情况的讨论 ····· 22
第 4 章 结论与展望 ····· 24
参考文献 ····· 25
致 谢 ····· 27

第 1 章　同态感知：背景

1.1　同态感知和其实例

同态感知（Homomorphic Sensing）[1] 是一个在抽象层面上研究从信号的同态像唯一恢复原信号的问题。为了严谨地介绍同态感知的具体研究内容，我们首先有如下的定义。

定义 1 (同态感知性质)**.** 考虑一个在 m 维空间内的向量集合 $\mathcal{V} \subset \mathbb{C}^m$ 和一个有限的 m 维线性变换的集合 $\mathcal{T}$。我们说 "$v_1 \in \mathcal{V}$ 在 $\mathcal{V}$ 和 $\mathcal{T}$ 下具有同态感知性质"，如果对于任意的 $\tau_1, \tau_2 \in \mathcal{T}$ 和 $v \in \mathcal{V}$ 都满足

$$\tau_1(v^*) = \tau_2(v) \Rightarrow v^* = v \tag{1.1}$$

直观来说，一个信号 v 具有同态感知性质，如果该信号可以唯一地由其同态像确定。根据以上的定义，同态感知研究可以保证所有的，或者几乎所有的 $\mathcal{V}$ 中的信号都具有同态感知性质的条件。通过实例化 $\mathcal{V}$ 和 $\mathcal{T}$，同态感知在诸多数据科学、工程领域中出现的问题有所应用。接下来我们介绍一些例子。

无标感知（*Unlabelled Sensing*）[2] 是同态感知的一个实例，其中 $\mathcal{T}$ 是所有选择矩阵（selection matrix）[1]的集合同时 $\mathcal{V}$ 是一个线性空间。该问题研究如何从某信号的经过乱序和降采样的线性测量中恢复原信号。当没有降采样时，$\mathcal{T}$ 是所有排列矩阵的集合，无标感知即退化为*无对应线性回归*（*Linear regression without correspondence*），或者 *乱序线性回归*（*Shuffled linear regression*）[3–6]。这一问题出现在诸多领域的应用中，如图像配准（image registration）[7]，姿势匹配估计（pose/correspondence estimation）[8,9]，多目标追踪（multi-target tracking）[10] 和数据连并（record linkage）[11,12]。

实相位恢复（*Real phase retrieval*）[13] 研究如何从某信号 $x^* \in \mathbb{R}^n$ 的线性测量的绝对值 $y \in \mathbb{R}^m$ 不区分正负号地恢复原信号。这一问题也可以被表述为同态感知的一个实例，其中 $\mathcal{T} = \mathcal{B}$ 是所有符号矩阵（sign matrix）[2]同时 $\mathcal{V}$ 是一个线性空间。*对称混合双线性回归*（*Symmetric mixture of two linear regressions*）[14] 也有该表述。严格来讲，我们观测到

$$y = B^* A x^* \tag{1.2}$$

[1]一个选择矩阵等价于一个坐标投影矩阵（coordinate projection）和一个排列矩阵（permutation matrix）的乘积。

[2]一个符号矩阵是一个对角元素均为 1 或 −1 的对角矩阵。

其中 $B^* \in \mathcal{B}$ 是一个未知符号矩阵，$A \in \mathbb{R}^{m\times n}$ 是一个已知的 $\mathcal{V}$ 的基矩阵，同时我们想不区分正负号地恢复未知信号 $x^* \in \mathbb{R}^n$。

在以上的例子中，$\mathcal{V}$ 都是线性空间，而在某些情况中这并不是最贴切的描述。举例来说，当我们考虑稀疏信号的恢复时，$\mathcal{V}$ 实际上是多个线性空间的并集。我们更加详细地阐释这一现象。我们说一个向量是 k-稀疏的如果它有不多于 k 个非零元素。假设 x^* 是一个 k-稀疏向量，同时我们观测到

$$y = TAx^* \tag{1.3}$$

其中 T 是一个未知的 $\mathcal{T}$ 中的 m 维的线性变换，$A \in \mathbb{C}^{m\times n}$ 是一个已知的满列秩矩阵。这里因为 x^* 是 k-稀疏的，Ax^* 存在于矩阵 A 的对应 k 个 x 的非零元素的 k 列张成的 k 维向量空间中。由于我们不知道哪 k 个 x^* 的元素是非零的，Ax^* 可能存在于一共 $\binom{n}{k}$ 个不同的 k-维向量空间，也因此 Ax^* 在这 $\binom{n}{k}$ 个线性空间的并集中。注意尽管我们仍然可以说 Ax^* 在 A 的所有列张成的空间（即 A 的列空间），这并非是最贴切和合适的描述，因为 x^* 的稀疏性没有被纳入考虑范围。通过用我们刚才描述的这一子空间的并集替换之前例子中的 $\mathcal{V}$，之前我们提到的的同态感知的实例便变为相应设定下稀疏信号的恢复问题，例如在[15] 与[16] 中所研究的稀疏实相位恢复。

以上讨论均假设无噪声模型，这一假设在实际应用中未免有些不实际。在某些同态感知的实例场景中，人们对于噪声模型有所研究。一个通常的模型假设是一个噪声向量 ϵ 被附加于我们观测到的信号上，所以我们观测到 $\bar{y} = T^*Ax^* + \epsilon$ 并想通过 $\bar{y}$ 来恢复 x^*。一个 x^* and T^* 的自然的估计器是最大似然估计器（maximum likelihood estimator）：

$$(\hat{T}, \hat{x}) \in \underset{T\in\mathcal{T}, x\in\mathbb{C}^n}{\arg\min} \|\bar{y} - TAx\|_2 \tag{1.4}$$

在无标感知的情景中，[2] 证明了这一估计器的局部稳定性，具体来说 $\|\hat{x}-x^*\|_2$ 在 $\|\epsilon\|_2$ 趋向于 0 时也趋向于 0。在乱序线性回归中，[4] 研究恢复正确的排列矩阵的信噪比要求。这一研究与同态感知的研究对象有所不同但也一定程度相关。同样是研究对于排列矩阵的恢复，[17] 证明在这些排列是稀疏的情况下，即这些排列矩阵只打乱 Ax^* 的一小部分元素的顺序时，信噪比的要求可以被降低。在我们所知的范围内，还没有在抽象层次研究噪声下同态感知的工作。

1.2 论文贡献与结构

[1] 首先提出同态感知，并给出在 $\mathcal{V}$ 是一个线性空间时能够保证信号同态感知性质的条件。基于这一工作，我们对同态感知做出如下两方面的贡献。

- 首先，在第2章中，我们将同态感知拓展到输入空间 $\mathcal{V}$ 是多个线性空间并集的情况。这项工作的应用之一在于一类稀疏信号恢复唯一性的问题，我们之前也进行了简要的讨论。
- 其次，在第3章中，我们研究噪声下的同态感知。我们首先给出能够保证 $\hat{x}$ 和 x^* 的误差相对较小的决定性条件，然后在 $\mathcal{T}$ 中元素的奇异值为 1 或 0 的假设下进行进行概率性的分析。这一假设可以应用于绝大部分目前同态感知的实例。具体来说，我们推导出如何将模型降维至 $n = 1$ 的情形，同时在 $\mathcal{T}$ 中的变换均额外为满秩时推导能够刻画信噪比与估测误差之间关系的概率性条件约束。我们同时也讨论 $\mathcal{T}$ 中变换为非满秩的情况，并猜想类似的结果可以被推导。我们将这放在未来工作。

1.3 符号惯例与背景知识

我们所使用的的大部分符号与记号都与[1] 相同，其中对于线性代数相关的符号也可以参照[18]。我们介绍一部分将会被频繁使用的记号。一个从某个向量空间到该向量空间自己的线性映射叫做自同态映射（endomorphism），同时一个可逆的自同态映射叫做自同构映射 (automorphism)。对于某个 $\mathbb{C}^m$ 的自同态映射 τ,，它的核，记作 $\ker(\tau)$，是所有被映射到 0 的向量，即 $\ker(\tau) = \{v \in \mathcal{C}^m : \tau(v) = 0\}$，同时其像空间为 $\mathrm{im}(\tau) = \{\tau(v) : v \in \mathbb{C}^m\}$。一个自同态映射的秩是其像空间的维度，即 $\mathrm{rank}(\tau) = \dim(\mathrm{im}(\tau))$。$\tau$ 的特征值 λ 对应的特征空间为如下的向量空间：$\mathcal{E}_{\tau,\lambda} = \{v \in \mathbb{C}^m : \tau(v) = \lambda v\}$。一个子空间 $\mathcal{V} \subset \mathbb{C}^m$ 的余维数（codimension）是其所在环绕空间（ambient space）的维度减去其本身的维度，即 $\mathrm{codim}(\mathcal{V}) = m - \dim(\mathcal{V})$。矩阵 X 的列空间记为 $\mathcal{R}(X)$，有时我们也用 $\mathrm{Span}(X)$ 表示。同时 X 的零空间记为 $\mathcal{N}(X)$。对于一个矩阵 A，我们用 P_A 代表至 $\mathcal{R}(A)$ 即 A 的列空间的正交投影矩阵，同时我们用在 $P_{A^\perp}$ 表示到 $\mathcal{R}(A)^\perp$ 上的正交投影矩阵。对于某个 m 维空间中的 n 维向量空间 $\mathcal{U}$，我们说 $A \in \mathbb{C}^{m\times n}$ 是 $\mathcal{U}$ 的基矩阵，如果 A 的列向量构成 $\mathcal{U}$ 的一组基。一个矩阵 X 的奇异值分解记为 $U_X\Sigma_X V_X^T$，其中 Σ_X 为一个对角矩阵，其对角元素为 X 的奇异值，同时大于 0 的奇异值的个数为 X 的秩。我们有时也用 $U_X\Sigma_X V_X^T$ 代表 X 的简奇异值分解（会在相应情况有所说明），这种分解省略 X 的 0 奇异值相关的奇异向量，同时 Σ_X 的大小为 $\mathrm{rank}(X) \times \mathrm{rank}(X)$。我们将矩阵的标准内积记为 $< X, Y >= \sum_{i,j} X_{ij}Y_{ij}$。

我们会用到一些代数几何的相关概念和结论[19]，其中一个非常重要的结论是有限个 Zariski 非空开集的交集也是一个 Zariski 非空开集。一个 $\mathbb{C}^m$ 中的代数簇是一个 m 变量多项式系统的解集。$\mathrm{Gr}(m,n)$ 代表在 $\mathbb{C}^m$ 中所有 n 维线性空间的集合，其本身也为一个代数簇同时被称作 Grassmannian。在第2章中我们会经常提及有限个线性子空间的并集，$\mathcal{V} = \bigcup_{i=1,\ldots,l} \mathcal{V}_i$。$\mathcal{V}$ 通常来讲不是一个线性子空间，但是是一个代数簇。$\mathcal{V}$ 的维度指其代数维度，其等于 $\mathcal{V}_i$ 中最大维度的子空间的维度，即 $\dim(\mathcal{V}) = \max_{i=1,\ldots,l} \dim(\mathcal{V}_i)$。我们说一个点在一个集合中是“一般”的如果它存在于某个测度为 1 的子集，所以读者可以将“一般”看作“从某一个连续概率分布中采样得到”。在这篇论文中，因为我们在代数几何的背景下，这个测度为 1 的集合通常为一个在 Zariski 拓扑下的非空开集。举例来说，当我们说 $\mathbb{C}^m$ 中一个一般的 n 维线性空间 $\mathcal{V}$ 时，这意味着 $\mathcal{V}$ 存在于某个在 $\mathrm{Gr}(m,n)$ 的 Zariski 拓扑下的非空开集 $\mathbb{U} \subset \mathrm{Gr}(m,n)$。当我们说一个在一些子空间并集 $\mathcal{V} = \bigcup_{i=1,\ldots,l} \mathcal{V}_i$ 中的一个一般向量 v 时，这意为存在非空开集 $\mathbb{U}_i \subset \mathcal{V}_i$ 使得 $v \in \bigcup_{i=1,\ldots,l} \mathbb{U}_i$。

我们会频繁用到以下引理。

引理 1. 让 $\mathcal{Y}$ 是一个由齐次多项式定义的代数簇，同时 $\mathcal{V}$ 是一个一般线性子空间。那么 $\dim(\mathcal{Y} \cap \mathcal{V}) = \max\{\dim(\mathcal{Y}) - \mathrm{codim}(\mathcal{V}), 0\}$。

最后，我们使用 C 来代表绝对常数，其中不同位置的 C 可能代表不同的常数。

第 2 章　多个子空间并集的同态感知

在这一章我们将同态感知的输入空间由单一线性空间拓展为多个线性空间的并集，并推导这一新情形下原始信号能被唯一恢复的条件。我们将推导出的结论应用于一类稀疏信号的恢复问题上。

2.1　可逆变换下的感知

我们首先考虑一个基础情况，其中 $\mathcal{T}$ 只包括恒等映射和一个可逆映射同时 $\mathcal{V}$ 是两个线性空间的并集。在已有理论的基础上这一情形的结论能够较容易推出。我们有如下引理。

引理 2 ([1] 中引理 2 的拓展)**.** *假设 $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$ 是两个不同的线性子空间的并集，其中 $\dim(\mathcal{V}_i) = n_i$。考虑 $\mathcal{T} = \{i, \tau\}$，其中 i 代表恒等变换（即 $i(v) = v$）同时 τ 是一个可逆的变换。在这一情形我们有：所有的 $v \in \mathcal{V}$ 满足同态感知性质当且仅当下列的四个条件（$a1, b1, c1, d1$）同时成立:*

$$
\begin{aligned}
&(a1)\ \mathcal{V}_1 \cap \tau(\mathcal{V}_1) \subset \mathcal{E}_{\tau,1} \\
&(b1)\ \mathcal{V}_2 \cap \tau(\mathcal{V}_2) \subset \mathcal{E}_{\tau,1} \\
&(c1)\ \mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \mathcal{V}_1) = \varnothing \\
&(d1)\ \mathcal{V}_2 \cap \tau(\mathcal{V}_1 \setminus \mathcal{V}_2) = \varnothing
\end{aligned}
\tag{2.1}
$$

证明.　在 $\{i, \tau\}$ 下对于任意的 $v \in \mathcal{V}$ 都有同态感知性质等价于:

$$
\begin{aligned}
&(a2)\ \forall x \in \mathcal{V}_1, \forall y \in \mathcal{V}_1, x = \tau(y) \Rightarrow x = y \\
&(b2)\ \forall x \in \mathcal{V}_2, \forall y \in \mathcal{V}_2, x = \tau(y) \Rightarrow x = y \\
&(c2)\ \forall x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, x = \tau(y) \Rightarrow x = y \\
&(d2)\ \forall x \in \mathcal{V}_2, \forall y \in \mathcal{V}_1 \setminus \mathcal{V}_2, x = \tau(y) \Rightarrow x = y
\end{aligned}
\tag{2.2}
$$

这四种情形中，前两种对应单一子空间的同态感知；因此由[1] 中的引理 2 我们有 $(a2) \Leftrightarrow (a1)$ 和 $(b2) \Leftrightarrow (b1)$。接下来，$(c2)$ 等价于

$$\forall x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, x \neq y \Rightarrow x \neq \tau(y)$$

对于 $x \in \mathcal{V}_1$ 和 $y \in \mathcal{V}_2 \setminus \mathcal{V}_1$, x 不可能等于 y，因此这等价于

$$\forall x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, x \neq \tau(y)$$

这也等价于 $(c1)$ $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \mathcal{V}_1) = \varnothing$. 类似的，$(d2)$ 等价于 $(d1)$ 因此引理得证。
□

直观来说，当信号来源于两个自空间的并集时，我们需要对于每一个子空间具有同态感知，也需要处理当两个信号分别来自这两个不同的子空间时，他们有可能被（可能经过不同的线性变换）映射到同一个像；这便是条件 $(c1)$ 和 $(d1)$ 所能够避免的。

$(c1), (d1)$ 中右侧的空集或许有些不自然；一个自然的化简想法是将 $(c1)$ 替换为 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2) = 0$（对于 $d1$ 类似）。然而这一替换只在一些特殊条件下成立；一些相关的可被证明的结论如下：

- 如果 $\mathcal{V}_1 \cap \mathcal{V}_2 = 0$，那么 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \mathcal{V}_1) = \varnothing \Rightarrow \mathcal{V}_1 \cap \tau(\mathcal{V}_2) = 0$；但是另一个方向并不一定成立：对于某个 $y \neq 0, y \in \ker(\tau) \cap \mathcal{V}_2$，我们有 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \mathcal{V}_1)$ 至少包含 0。
- 如果 $\mathcal{V}_1 \cap \mathcal{V}_2 = 0$ 同时 $\mathcal{V}_2 \cap \ker(\tau) = 0$, 那么 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \mathcal{V}_1) = \varnothing \Leftrightarrow \mathcal{V}_1 \cap \tau(\mathcal{V}_2) = 0$.

以上两条的证明较为显然，并且在引理3和引理4中被隐式地证明了；因此我们在这里省略证明。

接下来，我们考虑对于一般子空间 $\mathcal{V}_1, \mathcal{V}_2$ 的情况。首先我们考虑一类特殊的线性变换，即可对角化（diagonalizable）的可逆线性变换。事实上，我们有如果对于每个线性子空间[1] 中提出的同态感知的条件均成立，那么我们在两个子空间的并集中的向量也具有同态感知。

引理 3 ([1] 中引理 3 的拓展)**.** *假设 τ 是一个可对角化且可逆的 $\mathbb{C}^m$ 的线性变换，同时 $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$ 是两个不同的一般子空间的并集，其中 $\dim(\mathcal{V}) \leq \lfloor m/2 \rfloor$。那么所有的 $v \in \mathcal{V}$ 都具有同态感知性质当且仅当 $\dim(\mathcal{V}) \leq \operatorname{codim}(\cup_{\lambda \neq 1} \mathscr{E}_{\tau,\lambda})$。*

证明. （$\Rightarrow$）根据引理2我们知道 $\mathcal{V}_1 \cap \tau(\mathcal{V}_1) \subset \mathscr{E}_{\tau,1}$ 同时 $\mathcal{V}_2 \cap \tau(\mathcal{V}_2) \subset \mathscr{E}_{\tau,1}$。这意味着 $\dim(\mathcal{V}) \leq \operatorname{codim}(\cup_{\lambda \neq 1} \mathscr{E}_{\tau,\lambda})$。（$\Leftarrow$）与引理2中类似，我们需要证明 $(a2), (b2), (c2), (d2)$ 来证明唯一恢复性。因为 $\dim(\mathcal{V}_1) \leq \dim(\mathcal{V})$ 和 $\dim(\mathcal{V}_2) \leq \dim(\mathcal{V})$，根据[1] 中的引理 3，$(a2), (b2)$ 成立。使用与引理2中相同的思路可以证明 $(c2), (d2)$ 与 $(c1), (d1)$ 等价。根据引理1我们有 $\dim(\mathcal{V}_1 \cap \mathcal{V}_2) = 0$，因此 $\mathcal{V}_1 \cap \mathcal{V}_2 = 0$ 所以 $\mathcal{V}_2 \setminus \mathcal{V}_1 = \mathcal{V}_2 \setminus \{0\}$。现在为了证明 $(c1)$ $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \mathcal{V}_1) = \varnothing$，我们需要证明 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \{0\}) = \varnothing$。因为 τ 是可逆变换，$\tau(\mathcal{V}_2 \setminus \{0\}) = \tau(\mathcal{V}_2) \setminus \{0\}$。我们现在需要证明 $\mathcal{V}_1 \cap (\tau(\mathcal{V}_2) \setminus \{0\}) = \varnothing$，易证这等价于证明 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2) = 0$。因为

$\dim(\tau(\mathcal{V}_2)) \leq \dim(\mathcal{V}_2)$ 同时 $\mathcal{V}_1$ 是一般的，根据引理1我们有 $\dim(\mathcal{V}_1 \cap \tau(\mathcal{V}_2)) \leq \dim(\mathcal{V}_2) + \dim(\mathcal{V}_1) - m \leq 0$。因此 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2) = 0$。 □

由如上结论，我们可以将同态感知拓展到多个可逆线性变换和多个自空间并集的情况。具体来讲，我们可以对于每一对线性变换和每一对子空间都施加引理3的条件，因此便可以保证在这种一般情况同态感知成立。这一结论由引理3以及有限个非空 Zariski 开集的交集依然是一个 Zariski 开集可以得出。注意从现在开始我们的维度指代数维度。

命题 1. *假设 $\mathcal{T}$ 是一个有限的多个 $\mathbb{C}^m$ 中的可逆变换的集合，同时对于 $\forall \tau_1, \tau_2 \in \mathcal{T}$ 我们都有 $\tau_1^{-1}\tau_2$ 是可对角化的。假设 $\mathcal{V} = \mathcal{V}_1 \cup \ldots \cup \mathcal{V}_l$ 是多个一般线性子空间的并集，其中 $\dim(\mathcal{V}) \leq \lfloor m/2 \rfloor$。那么 $\mathcal{V}$ 在 $\mathcal{T}$ 下具有同态感知性质当且仅当对于任意的 $\tau = \tau_1^{-1}\tau_2$，$\tau_1, \tau_2 \in \mathcal{T}$，$\dim(\mathcal{V}) \leq \operatorname{codim}(\cup_{\lambda \neq 1} \mathcal{E}_{\tau,\lambda})$ 都成立。*

证明. (⇒) 任意选择 $\tau_1, \tau_2 \in \mathcal{T}$ 和 $v_1, v_2 \in \mathcal{V}_i$ 对于所有的 i，我们可以得出 $\dim(\mathcal{V}_i) \leq \operatorname{codim}(\cup_{\lambda \neq 1} \mathcal{E}_{\tau,\lambda})$ 对于任意的 i，因此对于任意的 τ_1, τ_2，$\dim(\mathcal{V}) \leq \operatorname{codim}(\cup_{\lambda \neq 1} \mathcal{E}_{\tau,\lambda})$。

(⇐) 假设对于 $v_i, v_j \in \mathcal{V}_i, \mathcal{V}_j$ 有 $\tau_1(v_i) = \tau_2(v_j)$。如果 $i = j$ 那么问题退化为单一子空间的同态感知，因此根据[1] 中的引理 3 成立。现在假设 $i \neq j$。因为 τ_1 是可逆的，$v_i = \tau_1^{-1}\tau_2(v_j)$，因此根据引理3同态感知性质成立。 □

2.2 任意变换

当 τ 不一定是可逆的时候，引理3的证明便不再成立；具体来说，$\tau(\mathcal{V}_2 \setminus \{0\}) \neq \tau(\mathcal{V}_2) \setminus \{0\}$ 因为现在 $\ker(\tau)$ 不仅仅只包含 0。但是这个问题可以由每个子空间的一般性解决；具体来讲现有条件可以确保我们找到一个子空间所在的 Zariski 开集，使得任意该开集中的子空间都与 $\ker(\tau)$ 只相交于 0。具体细节参考证明。

引理 4 ([1] 中引理 4 的拓展)**.** *让 $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$ 是两个一般线性子空间的并集，其中 $\dim(\mathcal{V}) \leq \lfloor m/2 \rfloor$ 同时 τ 是满足 $\dim(\mathcal{V}) \leq \operatorname{codim}(\cup_{\lambda \neq 1} \mathcal{E}_{\tau,\lambda})$ 的任意的 $\mathbb{C}^m$ 中的线性变换。那么 $\mathcal{V}$ 在 $\{i, \tau\}$ 下具有同态感知性质。*

证明. 同样的，我们需要证明 $(a2), (b2), (c2), (d2)$ in (2.2) 来证明同态感知。根据[1] 中的引理 4，$(a2), (b2)$ 已经成立。使用与3中相同的方法可以证明 $(c2), (d2)$ 等价于 $(c1), (d1)$，$\mathcal{V}_1 \cap \mathcal{V}_2 = 0$ 同时 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2) = 0$。为了证明 $(c1)$ 我们需要证明 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \setminus \{0\}) = \varnothing$。使用反证法，假设这是错的，那么存在 $x \in \mathcal{V}_1, y \in \mathcal{V}_2, y \neq 0$

使得 $\tau(y) = x$ 因此 $x \in \tau(\mathcal{V}_2) \cap \mathcal{V}_1$，从这可以推出 $x = 0$。现在 $\tau(y) = 0$ 所以 $y \in \ker(\tau) \cap \mathcal{V}_2$。因为 $\dim(\mathcal{V}_2) \leq \operatorname{codim}(\mathscr{E}_{\tau,0}) = m - \dim(\ker(\tau))$ 根据引理1, $\dim(\ker(\tau) \cap \mathcal{V}_2) = 0$ 所以 $\ker(\tau) \cap \mathcal{V}_2 = 0$，也因此 $y = 0$，引出矛盾。用类似的方法我们证明 $(d1)$。 □

利用如上所述的引理我们可以有以下定理。在给出我们的定理之前，如[1] 中我们定义

$$\mathcal{Y}_{\rho\tau_1,\tau_2} = \{w : \dim(\operatorname{Span}(\rho\tau_1(w), \tau_2(w))) \leq 1\} \tag{2.3}$$

$$\mathcal{Z}_{\rho\tau_1,\tau_2} = \ker(\tau_2) \cup \ker(\rho\tau_1) \cup \ker(\rho\tau_1 - \tau_2) \tag{2.4}$$

$$\mathcal{U}_{\rho\tau_1,\tau_2} = \mathcal{Y}_{\rho\tau_1,\tau_2} \setminus \mathcal{Z}_{\rho\tau_1,\tau_2} \tag{2.5}$$

定理 1 ([1] 中定理 1 的拓展)**.** *让 $\mathcal{V} = \mathcal{V}_1 \cup \ldots \cup \mathcal{V}_l$ 是有限个一般线性子空间的并集，$\dim(\mathcal{V}) = n$ 假设 $\mathcal{T}$ 是有限个 $\mathbb{C}^m$ 中的线性变换，其中 $m \geq 2n$ 并且对任意的 $\tau \in \mathcal{T}$ 我们都有 $rank(\tau) \geq 2n$。那么 $\mathcal{V}$ 在 $\mathcal{T}$ 下具有同态感知性质，如果对于所有 $\tau_1, \tau_2 \in \mathcal{T}$ 都存在一个向 $\operatorname{im}(\tau_2)$ 的线性投影使得 $\dim(\mathcal{V}) \leq \operatorname{codim}(\mathcal{U}_{\rho\tau_1,\tau_2})$。*

证明. 我们的证明与[1] 中的证明思路较为类似。首先，考虑 $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$ 和 $\mathcal{T} = \{\tau_1, \tau_2\}$ 的情况便已足够。让 $\dim(\mathcal{V}_1) = n_1$ ，$\dim(\mathcal{V}_2) = n_2$，那么 $n_1 \leq n, n_2 \leq n$。假设对于 $x, y \in \mathcal{V}$ 有 $\tau_1(x) = \tau_2(y)$。让 $k = \operatorname{rank}(\tau_2)$。因为 $k \geq 2n_1$，$k \geq 2n_2$ 我们可以将 $\mathcal{V}_1$ 和 $\mathcal{V}_2$ 看作一个一般的 k-维线性空间 $\mathcal{H}$ 的两个一般线性子空间。现在 $\rho\tau_1|_{\mathcal{H}}(x) = \tau_2|_{\mathcal{H}}(y)$，其中 ρ 是到 $\operatorname{im}(\tau_2)$ 上的投影。因为 $\mathcal{H}$ 是一般的，我们有 $\mathcal{H} \cap \ker(\tau_2) = 0$ 也因此 $\tau_2|_{\mathcal{H}}$ 在 $\mathcal{H}$ 和 $\operatorname{im}(\tau_2)$ 之间建立了双射，也因此 $(\tau_2|_{\mathcal{H}})^{-1}\rho\tau_1|_{\mathcal{H}}(x) = y$。让 $\tau_{\mathcal{H}} = (\tau_2|_{\mathcal{H}})^{-1}\rho\tau_1|_{\mathcal{H}}$。根据引理4我们有同态感知成立如果给定 $\dim(\mathscr{E}_{\tau_H,\lambda\neq 1}) \leq k - n$。因为 $\mathscr{E}_{\tau_{\mathcal{H}},\lambda}$ 和 $\mathscr{E}_{(\rho\tau_1,\tau_2),\lambda\neq 1} \cap \mathcal{H}$ 通过 $\tau_2|_{\mathcal{H}}$ 建立了双射，我们想证明的与证明 $\dim(\mathscr{E}_{(\rho\tau_1,\tau_2),\lambda\neq 1} \cap \mathcal{H}) \leq k - n$ 等价。对于 $\lambda \neq 0, 1$, $(\mathscr{E}_{(\rho\tau_1,\tau_2),\lambda} \cap \mathcal{H}) \subset (\mathcal{U}_{\rho\tau_1,\tau_2} \cap \mathcal{H}) \subset (\bar{\mathcal{U}}_{\rho\tau_1,\tau_2} \cap \mathcal{H})$ 因此根据引理1 $\dim(\mathscr{E}_{(\rho\tau_1,\tau_2),\lambda} \cap \mathcal{H}) \leq k - n$。现在我们还需要证明 $\lambda = 0$ 的情况。如果 $\dim(\mathscr{E}_{(\rho\tau_1,\tau_2),0}) \leq m - n$ 那么结论成立，因为 $\mathcal{H}$ 是 k-维的一般空间，所以 $\mathcal{H}$ 和 $\mathscr{E}_{(\rho\tau_1,\tau_2),0}$ 相交于最多 $[(m-n)+k] - m = k - n$ 维。如果 $\dim \mathscr{E}_{(\rho\tau_1,\tau_2),0} = \dim(\ker(\rho\tau_1)) \geq m - n$，那么 $\operatorname{im}(\tau_2)$ 会与 $\operatorname{im}(\rho\tau_1)$ 的任意补空间 C 相交于至少 $[(m-n)+k] - m = k - n \geq n$ 维。让 σ 到 $C \cap \operatorname{im}(\tau_2)$ 的映射。对 $\rho\tau_1(x) = \tau_2(y)$ 的等式两边同时用 σ 变换我们得到 $0 = \sigma\tau_2(y)$，所以 $y \in \ker(\sigma\tau_2) \cap \mathcal{V}$。因为 $\dim(\ker(\sigma\tau_2)) \leq m - n$，我们有 $\mathcal{V}_1 \cap \ker(\sigma\tau_2) = 0$ 和 $\mathcal{V}_2 \cap \ker(\sigma\tau_2) = 0$，所以

$y = 0$。因此 $\tau_1(x) = \tau_2(y)$ 可以推出 $\tau_1(x) = 0$。现在我们有 $x \in \ker(\tau_1) \cap \mathcal{V}$。因为 $\dim(\ker(\tau_1)) \leq m - n$，$\ker(\tau_1) \cap \mathcal{V}_1 = 0$ 和 $\ker(\tau_1) \cap \mathcal{V}_2 = 0$ 我们有 $x = 0$。 □

目前我们的结论都针对点集 $\mathcal{V}$ 中所有向量的同态感知；这一讨论目标在实际应用中或许会有些过于严格。在许多情况下，我们不需要考虑所有信号的同态感知；一般信号的同态感知也是较强的理论保证，因为这即代表 $\mathcal{V}$ 中几乎所有的点均有同态感知性质。在这一情况下，类似的，在输入空间是多个子空间并集时，我们有如下结论。

定理 2 ([1] 中定理 2 的拓展)**.** *让 $\mathcal{T}$ 是一个有限的 $\mathbb{C}^m$ 中的自同态映射的集合。那么在有限个一般线性空间交集 $\mathcal{V} = \mathcal{V}_1 \cup \ldots \cup \mathcal{V}_l$, $\dim(\mathcal{V}) = n$ 中的某一个一般向量 v 在 $\mathcal{V}$ 和 $\mathcal{T}$ 下具有同态感知性质，如果对于每个 $\tau \in \mathcal{T}$ 都满足 $\operatorname{rank}(\tau) \geq n + 1$，同时 $\mathcal{T}$ 中没有两个自同态映射是彼此的倍数。*

证明. 考虑 $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$ 并且 $\mathcal{T} = \{\tau_1, \tau_2\}$ 的情况便足够。首先让 $\dim(\mathcal{V}_1) = n_1$，$\dim(\mathcal{V}_2) = n_2$，因此 $n_1 \leq n, n_2 \leq n$。现在我们需要证明如下几点。

$$(a)\ \text{对于一般的} x \in \mathcal{V}_1, \forall y \in \mathcal{V}_1, \tau_1(x) = \tau_2(y) \Rightarrow x = y$$

$$(b)\ \text{对于一般的} x \in \mathcal{V}_2, \forall y \in \mathcal{V}_2, \tau_1(x) = \tau_2(y) \Rightarrow x = y$$

$$(c)\ \text{对于一般的} x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, \tau_1(x) = \tau_2(y) \Rightarrow x = y$$

$$(d)\ \text{对于一般的} x \in \mathcal{V}_2, \forall y \in \mathcal{V}_1 \setminus \mathcal{V}_2, \tau_1(x) = \tau_2(y) \Rightarrow x = y$$

根据[1] 中的定理 2，$(a), (b)$ 成立。(c) 等价于

$$\text{对于一般的} x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, \tau_1(x) \neq \tau_2(y)$$

假设 $\tau_1(x) = \tau_2(y)$。让 $V_1 \in \mathbb{C}^{m \times n_1}$ 是 $\mathcal{V}_1$ 的基矩阵，同时 $V_2 \in \mathbb{C}^{m \times n_2}$ 是 $\mathcal{V}_2$ 的基矩阵。因为 $\mathcal{V}_1$ 和 $\mathcal{V}_2$ 是一般的，V_1 和 V_2 也相应的是一般的。因为 $\tau_1(x) = \tau_2(y)$，我们有 $\tau_1(x) \in \tau_2(\mathcal{V}_2 \setminus \mathcal{V}_1) \subset \tau_2(\mathcal{V}_2)$。让 $x = V_1\xi$，其中 ξ 是一个一般向量，$\xi \in \mathbb{C}^{n_1}$。那么 $\operatorname{rank}([T_2V_2 \ \ T_1V_1\xi]) \leq n_2$，这对于一般的 $\mathcal{V}_1, \mathcal{V}_2, \xi$ 不可能发生。这是因为使得 $\operatorname{rank}([T_2V_2 \ \ T_1V_1\xi]) = n_2 + 1$ 成立的 $\mathcal{V}_1, \mathcal{V}_2, \xi$ 构成 $\mathrm{Gr}(n_1, m) \times \mathrm{Gr}(n_2, m) \times \mathbb{C}^{n_1}$ 的一个非空 Zariski 开集。接下来我们证明这一点。首先，它是一个开集，因为其由矩阵 $[T_2V_2 \ \ T_1V_1\xi]$ 的每个 $(n_2 + 1) \times (n_2 + 1)$ 子矩阵的行列式对应的多项式构成的解集的补集所定义。其次，可以证明其为非空集合。由于 V_1, ξ 是一般的，$T_1V_1\xi$ 是 $\mathcal{R}(T_1)$ 中的一个一般向量。注意 $\mathcal{R}(T_1)$ 的维度不小于 $n + 1$。因为 $\dim(\mathrm{Span}(T_2V_2)) \leq n_2 \leq n < \dim(\mathcal{R}(T_1))$，$\mathcal{R}(T_1) \setminus \mathrm{Span}(T_2V_2)$ 对于任意选择的 V_2

都是一个非空集合。选择某些使 $T_1V_1\xi \in \mathcal{R}(T_1) \setminus \mathrm{Span}(T_2V_2)$ 满足的 V_1 和 ξ，那么我们有 $\mathrm{rank}([T_2V_2\ \ T_1V_1\xi]) = n_2+1$，所以该集合为非空集合。类似的我们可以证明 (d)。 □

2.3 稀疏信号恢复

在这一节我们对一类稀疏信号恢复问题的唯一性给出理论保证。我们说一个点 $x \in \mathbb{C}^n$ 是一个 k-稀疏向量如果 $\|x\|_0 \le k$，其中 $\|\cdot\|$ 是某向量中非零元素的个数。同时，我们说 x 是一个一般 k-稀疏向量，如果它是 k-稀疏的并且其 k 个非零元素均为一般的。注意在这里我们说 k 个非零元素，而不是“不多于 k 个非零元素”，因为只有少于 k 的非零元素对应的向量构成的集合测度为 0，因此一般的 x 不会在这一集合中。延续之前所用的记号，我们感兴趣于如下问题：在什么条件下我们有对于 k-稀疏，或者一般 k-稀疏向量 x_1, x_2 和一个一般矩阵 $A \in \mathbb{C}^{m\times n}$，当 $T_1Ax_1 = T_2Ax_2$ 时则 $x_1 = x_2$?

一个我们在论文第一章讨论过的很重要的观察是，对于一个 k-稀疏向量 x，Ax 存在于由 A 的对应 x 的 k 个非零元素的列所张成的子空间中。因此当我们不知道 x 的哪 k 个元素为非零元素时，共有 $\binom{n}{k}$ 种可能的子空间。因此 Ax 存在于这 $\binom{n}{k}$ 个 k 维向量空间的并集中，其中每个子空间都由 A 的 k 列张成。然而，我们不能直接应用在前文中推导出的结论，因为这 $\binom{n}{k}$ 个子空间尽管每个都是一般子空间，它们在一起并不是一般的。具体来说，他们可能会相较于一般的子空间而言拥有更大的交集。我们举例阐释这一现象。假设 n 足够大并且 $k = 2$。那么由 $A_{:,1}$，$A_{:,2}$ 张成的自空间和由 $A_{:,1}$，$A_{:,3}$ 张成的子空间都包含 $A_{:,1}$，但前述结论考虑的情况并不包括这一情形。然而这一问题很容易被解决，具体来说我们有如下的两个引理，他们是前文结论的一个简单拓展。。

引理 5. 让 $\mathcal{W}_1, \mathcal{W}_2, \mathcal{W}_3$ 是三个 $\mathbb{C}^m$ 中的一般子空间，其维度分别为 d_1, d_2, d_3，其中 $d_1 \ge 1$，$d_2 \ge 1$，$d_1 + d_3 \le m, d_2 + d_3 \le m$。让 $\mathcal{V}_1 = \mathcal{W}_1 + \mathcal{W}_3$，$\mathcal{V}_2 = \mathcal{W}_2 + \mathcal{W}_3$，同时 $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$。假设 $\mathcal{T}$ 是一个有限的 $\mathbb{C}^m$ 中自同态映射的集合，其中对任意 $\tau \in \mathcal{T}$ 都有 $\mathrm{rank}(\tau) \ge 2(\max(d_1, d_2) + d_3)$。那么我们有所有 $\mathcal{V}$ 中的向量均具有同态感知性质，如果对于任意 $\tau_1, \tau_2 \in \mathcal{T}$，都存在一个到 $\mathrm{im}(\tau_2)$ 上的投影 ρ 使得 $\dim(\mathcal{V}) \le \mathrm{codim}(\mathcal{U}_{\rho\tau_1,\tau_2})$。

证明. 首先，我们证明一个“改”版的引理4，其中 $\mathcal{V}$ 的新的定义如该命题描述中所示。依旧，我们需要证明 $(a2)$，$(b2)$，$(c2)$ 和 $(d2)$。$(a2)$ 与 $(b2)$ 根据[1] 中的引

理 4 成立。$(c2)$ 和 $(d2)$ 与 $(c1)$ 和 $(d1)$ 等价，同时因为它们是对称的，我们如下只证明 $(c1)$。首先因为 $\mathcal{V}_1 \cap \mathcal{V}_2 = \mathcal{W}_3$，我们只需要证明 $\mathcal{V}_1 \cap \tau(\mathcal{V}_2 \backslash \mathcal{W}_3) = \varnothing$。假设这是错的，那么存在 $w_1 \in \mathcal{W}_1, w_2 \in \mathcal{W}_2$ 和 $w_3, w_3' \in \mathcal{W}_3$ 使得 $w_1 + w_3' = \tau(w_2) + \tau(w_3)$ 同时 $w_2 \neq 0$。这意味着 $w_1 \in \mathcal{W}_1 \cap (\tau(\mathcal{W}_2) + \tau(\mathcal{W}_3) + \mathcal{W}_3)$，而这一空间的维度不多于 $d_1 + d_2 + 2d_3 - m = \dim(\mathcal{V}_1) + \dim(\mathcal{V}_2) - m \leq 0$，因此 $w_1 = 0$，也所以 $\tau(w_2 + w_3) = w_3'$。这里注意 $w_2 + w_3$ 和 w_3' 都是 $\mathcal{V}_2$ 中的向量，而我们已经证明了 $\mathcal{V}_2$ 中所有向量都具有同态感知性质，因此 $w_2 + w_3 = w_3'$。这意味着 $w_2 \in \mathcal{W}_2 \cap \mathcal{W}_3$，因此 $w_2 = 0$，矛盾。到这里我们完成了“改”版引理4的证明。现在按照定理1的证明过程我们即可以证明该命题，其中有两个不同处：首先，将 $\mathcal{H}$ 定义为一个 $d_1 + d_2 + d_3$ 维的包含 $\mathcal{V}_1$ 和 $\mathcal{V}_2$ 的一般空间；其次使用我们上述证明的“改”版的引理4而非是原来的引理4。 □

引理 6. 让 $\mathcal{W}_1, \mathcal{W}_2, \mathcal{W}_3$ 是三个 $\mathbb{C}^m$ 中的一般子空间，其维度分别为 d_1, d_2, d_3，其中 $d_1 \geq 1$，$d_2 \geq 1$，$d_1 + d_3 \leq m, d_2 + d_3 \leq m$。让 $\mathcal{V}_1 = \mathcal{W}_1 + \mathcal{W}_3$，$\mathcal{V}_2 = \mathcal{W}_2 + \mathcal{W}_3$。假设 $\mathcal{T}$ 是一个有限的 $\mathbb{C}^m$ 中自同态映射的集合。那么每个一般的 $\mathcal{V}_1 \cup \mathcal{V}_2$ 中的向量 v 具有同态感知，如果对于任意 $\tau \in \mathcal{T}$ 都有 $\operatorname{rank}(\tau) \geq \max(d_1, d_2) + d_3 + 1$，同时没有两个 $\mathcal{T}$ 中的自同态映射是互相的倍数。

证明. 我们需要证明如下四点。这里 τ_1 和 τ_2 可以是相同的。

(a) 对于一般的$x \in \mathcal{V}_1, \forall y \in \mathcal{V}_1, \tau_1(x) = \tau_2(y) \Rightarrow x = y$

(b) 对于一般的$x \in \mathcal{V}_2, \forall y \in \mathcal{V}_2, \tau_1(x) = \tau_2(y) \Rightarrow x = y$

(c) 对于一般的$x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, \tau_1(x) = \tau_2(y) \Rightarrow x = y$

(d) 对于一般的$x \in \mathcal{V}_2, \forall y \in \mathcal{V}_1 \setminus \mathcal{V}_2, \tau_1(x) = \tau_2(y) \Rightarrow x = y$

根据[1] 中的定理 2，$(a), (b)$ 成立。(c) 等价于

(e) 对于一般的$x \in \mathcal{V}_1, \forall y \in \mathcal{V}_2 \setminus \mathcal{V}_1, \tau_1(x) \neq \tau_2(y)$

首先假设 $\tau_1 \neq \tau_2$。在这种情况我们会证明 $\tau_1(x) = \tau_2(y)$ 不可能发生。假设 $\tau_1(x) = \tau_2(y)$。让 W_i 是 $\mathcal{W}_i$ 的基矩阵，那么 $\mathcal{V}_1$ 的基矩阵为 $V_1 = [W_1; W_3]$ 同时 $\mathcal{V}_2$ 的基矩阵为 $V_2 = [W_2; W_3]$。由于 $\tau_1(x) = \tau_2(y)$ 我们有 $\tau_1(x) \in \tau_2(\mathcal{V}_2 \backslash \mathcal{V}_1) \subset \tau_2(\mathcal{V}_2)$。让 $x = V_1\xi$，其中 ξ 是一个一般向量，$\xi \in \mathbb{C}^{d_1+d_3}$。那么 $[T_2V_2 \;\; T_1V_1\xi]$ 没有满列秩，而这对于一般的 $\mathcal{W}_1, \mathcal{W}_2, \mathcal{W}_3, \xi$ 不可能发生，这是因为使得 $[T_2V_2 \;\; T_1V_1\xi]$ 满列秩的 $\mathcal{W}_1, \mathcal{W}_2, \mathcal{W}_3, \xi$ 构成 $\mathrm{Gr}(d_1, m) \times \mathrm{Gr}(d_2, m) \times \mathrm{Gr}(d_3, m) \times \mathbb{C}^{d_1+d_3}$ 的一个非空开

集。首先其显然为开集；其次我们可以找出其中的一个元素以证明其非空。让 $v \in \mathbb{C}^m$ 使得 $\tau_1(v)$ 和 $\tau_2(v)$ 线性独立。让 C 是 $\mathrm{im}(\tau_2)$ 中 $\mathrm{im}(\tau_2) \cap \mathrm{Span}(\tau_1(v), \tau_2(v))$ 的一个补空间。那么 $\dim(C) \geq \max(d_1, d_2) + d_3 - 1$。因为 $d_1 \geq 1, d_2 \geq 1$，我们有 $\dim(C) \geq d_1 - 1, \dim(C) \geq d_2 - 1, \dim(C) \geq d_3$。因此我们可以找出 $\mathcal{U}_1, \mathcal{U}_2, \mathcal{U}_3 \subset C$ 使得 $\dim(\mathcal{U}_1) = d_1 - 1$，$\dim(\mathcal{U}_2) = d_2 - 1$，$\dim(\mathcal{U}_3) = d_3$。让 $\mathcal{W}_1', \mathcal{W}_2', \mathcal{W}_3$ 分别是 $d_1 - 1, d_2 - 1, d_3$ 维的子空间并使得 $\tau_2(\mathcal{W}_1') = \mathcal{U}_1, \tau_2(\mathcal{W}_2') = \mathcal{U}_2, \tau_2(\mathcal{W}_3) = \mathcal{U}_3$。现在让 $\mathcal{W}_1 = \mathcal{W}_1' + \mathrm{Span}(v)$ 同时 $\mathcal{W}_2 = \mathcal{W}_2' + \mathrm{Span}(v)$。我们有 $v \in \mathcal{W}_1 + \mathcal{W}_3$ 同时 $\dim(\tau_1(v) + \tau_2(\mathcal{W}_2 + \mathcal{W}_3)) = d_2 + d_3 + 1$。类似地我们可以证明 (d)。

现在假设 $\tau_1 = \tau_2$。那么 $x - y \in \ker(\tau_1)$。让 $x = w_1 + w_3^{(1)}$，$y = w_2 + w_3^{(2)}$，其中 $w_1 \in \mathcal{W}_1, w_2 \in \mathcal{W}_2, w_3^{(1)}, w_3^{(2)} \in \mathcal{W}_3$，同时 $w_1, w_3^{(1)}$ 为一般向量。那么 $w_1 \in \ker(\tau_1) + \mathcal{W}_2 + \mathcal{W}_3$。这不可能发生，因为 $\dim(\ker(\tau_1) + \mathcal{W}_2 + \mathcal{W}_3) < m$ 同时 w_1 是 $\mathcal{W}_1$ 中的一般向量。类似地我们可以证明 (d)。 □

在稀疏信号恢复的情景中实例化以上的结论，我们有如下的命题。

定理 3. *让 $\mathcal{T}$ 是 $\mathbb{C}^{m\times m}$ 中有限个矩阵的集合。假设 $A \in \mathbb{C}^{m\times n}$ 是一个一般矩阵。假设我们有 k-稀疏向量 $x_1, x_2 \in \mathbb{C}^n$，以及 $T_1, T_2 \in \mathcal{T}$。那么*

- *如果对于任意 $T \in \mathcal{T}$ 都有 $\mathrm{rank}(T) \geq 2k$，同时对任意 $T_1, T_2 \in \mathcal{T}$ 都存在一个到 $\mathcal{R}(T_2)$ 上的投影矩阵 P 使得 $dim(\mathcal{U}_{PT_1,T_2}) \leq m - k$，那么 $T_1Ax_1 = T_2Ax_2$ 意味着 $x_1 = x_2$。*
- *当 x_1, x_2 为一般 k-稀疏向量时，如果每个 $\mathcal{T}$ 中元素的秩都至少为 $k+1$ 同时没有互相互为倍数的元素，那么 $T_1Ax_1 = T_2Ax_2$ 意味着 $x_1 = x_2$。*

证明. 对于一个 k-稀疏向量 x，如果其非零元素的索引集为 I，那么 Ax 是 $\mathcal{R}(A_{:,I})$ 中的向量，其中 $\mathcal{R}(A_{:,I})$ 是 A 中由 I 对应的列所张成的空间同时其维度为 k。假设 $T_1Ax_1 = T_2Ax_2$。让 x_1 对应的索引集为 I，x_2 的索引集为 J。假设 $I = J$ 那么该问题退化为单一子空间情形，由[1] 中的定理 1 和定理 2，以上两断言成立，所以 $Ax_1 = Ax_2$。让 x_1, x_2 中非零元素构成的子向量分别为 ξ_1, ξ_2，注意 $\xi_1, \xi_2 \in \mathbb{C}^k$，那么 $A_{:,I}\xi_1 = A_{:,I}\xi_2$。这意味着 $\xi_1 = \xi_2$ 因为 $m \leq k$。现在 $\xi_1 = \xi_2$ 和 $I = J$ 一起可以得出 $x_1 = x_2$。接下来，我们讨论 $I \neq J$ 的情况。假设 $|I \cap J| = d$，其中 $0 \leq d \leq k-1$。让 $\mathcal{W}_1 = \mathcal{R}(A_{:,I\setminus J})$，$\mathcal{W}_2 = \mathcal{R}(A_{:,J\setminus I})$ 同时 $\mathcal{W}_3 = \mathcal{R}(A_{:,I\cap J})$。那么 $\dim(\mathcal{W}_1) = \dim(\mathcal{W}_2) = k - d \geq 1, \dim(\mathcal{W}_3) = d$。现在我们分别证明命题中的两条断言。

- **第一条断言：** 现在 $Ax_1 \in \mathcal{W}_1 + \mathcal{W}_2$ 同时 $Ax_2 \in \mathcal{W}_2 + \mathcal{W}_3$。根据引理5我们有 $T_1Ax_1 = T_2Ax_2$ 意味着 $Ax_1 = Ax_2$。现在，$x_1 - x_2$ 最多有 $2k$ 个非零元素，所以

$x_1 - x_2$ 在一个维度最多为 $2k$ 的线性空间中（实际上，该空间是由 $I \cup J$ 所索引的标准基向量张成的空间。将该空间称为 U。现在 $x_1 - x_2 \in U \cap \mathcal{N}(A)$。由于 A 是一般的，$U \cap \mathcal{N}(A)$ 的维度不超过 $2k + n - m - n = 2k - m \leq 0$。这意味着 $x_1 = x_2$。

- **第二条断言：** Ax_1 是 $\mathcal{W}_1 + \mathcal{W}_2$ 中的一个一般向量，同时 $Ax_2 \in \mathcal{W}_2 + \mathcal{W}_3$。因为 $\max(\dim(\mathcal{W}_1), \dim(\mathcal{W}_2)) + \dim(\mathcal{W}_3) = k - d + d = k \leq \operatorname{rank}(T_i)$，根据引理6我们有 $T_1Ax_1 = T_2Ax_2$ 意味着 $Ax_1 = Ax_2$。现在 $x_1 - x_2 \in \mathcal{N}(A)$。让 k 维空间 $\mathcal{U}_1, \mathcal{U}_2$ 相应地代表由 I and J 对应的标准基向量所张成的空间（注意 $\mathcal{U}_1 \neq \mathcal{U}_2$。现在 $x_1 \in (\mathcal{U}_2 + \mathcal{N}(A))$，但这对于一个一般向量 $x_1 \in \mathcal{U}_1$ 不可能发生，因为使得 $x_1 \notin (\mathcal{U}_2 + \mathcal{N}(A))$ 满足的 (x_1, A) 构成集合是一个非空开集。首先其显然是一个开集，其次我们可以举例找出集合中某个 x_1, A。首先注意 $\dim(\mathcal{U}_2 + \mathcal{N}(A)) \leq k + n - m \leq n - 1$。选取 $x_1 \in \mathcal{U}_1 \setminus \mathcal{U}_2$ 同时选取 A 使得 $\mathcal{U}_2 + \mathcal{N}(A)$ 是 $\operatorname{Span}(x_1)$ 的任意补空间的子空间，我们有 $x_1 \notin (\mathcal{U}_2 + \mathcal{N}(A))$。因此 $x_1 = x_2$。

□

通过实例化以上结论中的 $\mathcal{V}$ 和 $\mathcal{T}$，我们可以将之前提及的同态感知许多实例拓展至稀疏信号恢复的情形。我们用一些例子来阐释这一点。

推论 1. *在乱序线性回归中，我们有 $\mathcal{T}$ 是所有大小为 $m \times m$ 的排列矩阵的集合，$\mathcal{V}$ 是某一般矩阵 $A \in \mathbb{C}^{m \times n}$ 的列空间。如果我们有 $m \geq 2k$，那么任意 k-稀疏向量 $x \in \mathbb{C}^n$ 都具有同态感知性质，换言之，$T_1Ax_1 = T_2Ax_2$ 意味着 $x_1 = x_2$。*

证明. 结合定理3和[1] 中的命题 3 可以直接得到该推论。 □

我们也提供一个在实相位恢复中的应用为例。在实相位恢复中，由于问题的本身结构信号只能不区分正负号得被恢复。这一点会让使用我们的结论多一些步骤。

推论 2. *在实相位恢复中，$\mathcal{T}$ 由所有的符号矩阵构成。当向量所在环绕空间的维度为 m 时，任意一个一般 k-稀疏向量都可以被不区分正负地唯一恢复，如果 $m \geq k + 1$。*

证明. 在这一情形中，易知两个 $\mathcal{T}$ 中矩阵 T_1, T_2 能为互相倍数的情况只可能为 $T_1 = T_2$ 或 $T_1 = -T_2$；这两种情况时 $T_1Ax_1 = T_2Ax_2$ 相应意味着 $x_1 = x_2$ 和 $x_1 = -x_2$。现在我们可以考虑 T_1 和 T_2 不是互相倍数的情况。按照定理3中相同的论证我们有 $T_1Ax_1 = T_2Ax_2$ 意味着 $x_1 = x_2$。所以当 $m \geq k + 1$ 时我们能够不区分正负号地唯一恢复 x_1。 □

第 3 章　噪声下的同态感知

在这一章我们研究噪声下的同态感知。我们着眼于分析 $\mathcal{V}$ 是一个线性空间时。

3.1　模型与相关假设

我们首先在这一节叙述我们的噪声下的模型假设。从这里开始我们会停止使用抽象线性代数的符号，而换成矩阵与坐标向量，因此这里 $\mathcal{T}$ 将代表原自同态映射相应的矩阵表示形式的集合。

让原始的无噪声感知模型为 $y = T^*Ax^*$，$T^* \in \mathcal{T}$，$x^* \in \mathbb{C}^n$，其中 A 是 $\mathcal{V}$ 的基矩阵。我们现在假设有额外的噪声 ϵ 附加在 y 上，因此我们观察到的信号变为 $\bar{y} = y + \epsilon$。同时，我们做出如下假设。

假设 1. A 是一个一般矩阵，同时在无噪声模型下能够保证所有 $\mathcal{V}$ 中向量在 $\mathcal{T}$ 下都具有同态感知性质的条件成立。

现在我们研究如下的对原始信号的估计器 $\hat{x}$ 和不同尺度的噪声向量 ϵ 之间的关系：

$$(\hat{T}, \hat{x}) \in \underset{T \in \mathcal{T}, x \in \mathbb{C}^n}{\arg\min} \|\bar{y} - TAx\|_2 \tag{3.1}$$

注意尽管这一估计器等价于假设噪声是独立同分布的高斯分布时的最大似然估计器，在这里我们不对 ϵ 做任何统计性的假设。事实上，我们后续的分析中与 ϵ 相关的量都只与其模长 $\|\epsilon\|_2$ 相关；因此在我们的分析结果后续加上对 ϵ 的概率性假设也可以非常轻松地获得相关的结论。举例来说，一个无疑最常用的噪声模型（前文也有提到）为 $\epsilon \in \mathbb{C}^m$ 的元素为独立同分布的高斯分布 $\mathcal{N}(0, \sigma^2)$，其中 σ 是每个元素的标准差。在这一情形下，当维度较高时，$\|\epsilon\|_2$ 将会非常集中地分布在半径为 $\sigma\sqrt{m}$ 的高维球壳附近，一个高维统计学中的经典结论（细节可见，例如[20] 中的定理 3.1.1）。

3.2　决定性分析

首先，我们定义如下的非空集合

$$\mathcal{T}_1 := \{T \in \mathcal{T} : y \in \mathcal{R}(TA)\} \tag{3.2}$$

该集合是非空的因为其至少包含 T^*。利用无噪声时能够保证同态感知性质的假设1，我们有如下结论。

引理 7. *在假设1下，如果 $\hat{T} \in \mathcal{T}_1$，那么 $\hat{T}A(\hat{x} - x^*) = P_{\hat{T}A}\epsilon$。*

证明. 因为 $\hat{T} \in \mathcal{T}_1$，存在某个 $\tilde{x}$ 使得 $\hat{T}A\tilde{x} = y = T^*Ax^*$。根据假设1这意味着 $\tilde{x} = x^*$，因此 $y = \hat{T}Ax^*$。现在

$$\hat{x} = \arg\min_x ||\hat{T}Ax^* - \hat{T}Ax + \epsilon||_2 \tag{3.3}$$

从这里可以容易看出 $\hat{T}A(\hat{x} - x^*) = P_{\hat{T}A}\epsilon$。 □

因此如果 $\hat{T} \in \mathcal{T}$，我们就在相对“好”的情况下。这样问题的中心自然就变为：什么条件可以保证 $\hat{T} \in \mathcal{T}_1$？在如下的引理中我们给出一个充分条件。

引理 8. *我们有 $\hat{T} \in \mathcal{T}_1$ 如果*

$$2||\epsilon||_2 < \max_{T \in \mathcal{T} \setminus \mathcal{T}_1} (||y||_2 - ||P_{TA}y||_2) \tag{3.4}$$

证明. 我们首先将 $\hat{T}$ 写为

$$\begin{aligned}
\hat{T} &= \arg\min_{T \in \mathcal{T}} \min_{w \in \mathcal{R}(TA)} ||\bar{y} - w||_2 \\
&= \arg\min_{T \in \mathcal{T}} \min_{w \in \mathcal{R}(TA)} (||w||_2^2 - 2\bar{y}^T w) \\
&= \arg\min_{T \in \mathcal{T}} \min_{\lambda > 0} \min_{w \in \mathcal{R}(TA), ||w||_2 = \lambda} (\lambda^2 - 2\bar{y}^T w) \\
&= \arg\min_{T \in \mathcal{T}} \min_{\lambda > 0} (\lambda^2 - 2\lambda \max_{w \in \mathcal{R}(TA), ||w||_2 = 1} \bar{y}^T w) \\
&= \arg\max_{T \in \mathcal{T}} \max_{w \in \mathcal{R}(TA), ||w||_2 = 1} \bar{y}^T w
\end{aligned} \tag{3.5}$$

现在我们只需要证明如下的结论便足够证明这一引理：对于任意的 $T_2 \in \mathcal{T} \setminus \mathcal{T}_1$，都存在某个 $T_1 \in \mathcal{T}_1$ 使得

$$\max_{w \in \mathcal{R}(T_1A), ||w||_2 = 1} \bar{y}^T w > \max_{w \in \mathcal{R}(T_2A), ||w||_2 = 1} \bar{y}^T w \tag{3.6}$$

这必然成立，如果如下的更强的条件成立：

$$\bar{y}^T y / ||y||_2 > \max_{w \in \mathcal{R}(T_2A), ||w||_2 = 1} \bar{y}^T w \tag{3.7}$$

现在 w_2 最大化该式右手侧的解之一，则这一条件等价于

$$||y||_2 > y^T w_2 + \epsilon^T w_2 - e^T y / ||y||_2 \tag{3.8}$$

现在因为 $y^T w_2 \le \max_{w \in \mathcal{R}(T_2 A), ||w||_2=1} y^T w$，$\epsilon^T w_2 \le ||\epsilon||_2$ 和 $\epsilon^T y \le ||\epsilon||_2 ||y||_2$，如果如下条件成立引理即可得证：

$$||y||_2 > 2||\epsilon||_2 + \max_{w \in \mathcal{R}(T_2 A), ||w||_2=1} y^T w \tag{3.9}$$

这一条件等价于

$$2||\epsilon||_2 < ||y||_2 - ||P_{TA} y||_2 \tag{3.10}$$

现在加上最外层在 $\mathcal{T} \setminus \mathcal{T}_1$ 集合的最大值，引理得证。 □

3.3 概率性分析

在这一部分我们对以上推导的决定性结论做概率性的分析。首先我们做出如下两条假设。

假设 2. n 维的线性空间 $\mathcal{V}$ 是 Grassmannian $\mathrm{Gr}(m, n)$ 中一个根据 Haar 测度均匀分布的随机子空间。

A 是 $\mathcal{V}$ 的基矩阵，因此 $\mathcal{V}$ 在 Haar 测度下为均匀分布等价于说 A 的元素为独立同分布的标准高斯分布，更多理论细节可见[20] 中的 5.2.6 节。这一假设是对于 $\mathcal{V}$ 一个相对标准和常见的概率性假设，例如其同时也被[3,4,17] 的分析所采用。

假设 3. 每个 $T \in \mathcal{T}$ 的奇异值均为 1 或者 0。

假设3看似是一个很强的假设，但实则不然：在绝大部分目前同态感知的应用场景中，这一假设均成立。例如：

- 在无标感知中，$\mathcal{T}$ 中所有选择矩阵的奇异值均为 1 或 0。
- 在乱序线性回归中，$\mathcal{T}$ 中所以排列矩阵的奇异值均为 1。
- 在实相位恢复中，$\mathcal{T}$ 中的符号矩阵的奇异值均为 1。
- 任何以排列矩阵为首的排列矩阵，坐标投影矩阵和符号矩阵的乘积的奇异值均为 1 或 0。

假设3对在假设2下的概率分析也至关重要，其具体原因是在一个奇异值为 1/0 的线性变换下的一个均匀分布的自空间的像仍然是一个均匀分布的子空间，而这一性质对于我们的概率分析至关重要。

现在我们定义在我们的模型下的信噪比（snr）和估测误差（err）。这两者之间的关系会是我们分析的重点：

$$\text{snr} = \frac{||x^*||_2}{||\epsilon||_2} \tag{3.11}$$

$$\text{err} = \frac{||\hat{x} - x^*||_2}{||\epsilon||_2} \tag{3.12}$$

我们现在开始概率性分析。从我们的决定性分析可以看出，一个很重要的步骤是约束 $\hat{\tau} \in \mathcal{T}$ 发生的概率，这样的话我们就可以较为轻松地约束估测误差。根据引理8，我们需约束 $2||\epsilon||_2 < \max_{T \in \mathcal{T} \setminus \mathcal{T}_1}(||y||_2 - ||P_{TA}y||_2)$ 发生的概率。由于最外围的取最大值可以由布尔不等式（Boole's Inequality）约束，我们需要对于某个 $T \in \mathcal{T} \setminus \mathcal{T}_1$ 约束如下事件的概率：

$$2||\epsilon||_2 < ||y||_2 - ||P_{TA}y||_2 \tag{3.13}$$

根据 A 的旋转不变性，我们可以将该问题的分析简化至 $x^* = ||x^*||_2 e_1$ 的情况，其中 e_1 是第一个标准基向量。因此 $Ax^* = ||x^*||_2 a$，其中 $a = A_{:,1}$ 是一个标准高斯向量。现在我们需要对如下事件的概率寻找下界：

$$P(\frac{2}{\text{snr}} < ||T^*a||_2 - ||P_{TA}T^*a||_2) \tag{3.14}$$

我们分几阶段进行分析。

3.3.1 降维至一维情形

让我们首先着眼于 $||P_{TA}T^*a||_2^2$。我们有如下的结论，其可以将问题中的矩阵 A 降维为 a。

引理 9. *在假设2和假设3下，*

$$||P_{TA}T^*a||_2^2 = (1 - X)||T^T T^*a||_2^2 + X||P_{Ta}T^*a||_2^2 \tag{3.15}$$

这里 $X = ||P_{r-n}^{r-1}v||_2^2$ 是一个随机投影的 2 范数的平方，同时是一个与 a 独立的随机变量，另外 $0 \le X \le 1$。这之中的 v 代表在 $r-1$ 维中的一个固定的标准基向量。

证明. 让 T 的简奇异值分解为 $U_T \Sigma_T V_T^T = U_T V_T^T$，其中 $U_T, V_T \in \mathbb{R}^{m \times r}$。我们会用到如下的一个简单引理。

引理 10. 让 U, X 为矩阵，v 为向量，同时它们都有合适的大小。如果 $U^T U = I$，那么

$$||P_{UX} v||_2^2 = ||P_X U^T v||_2^2 \tag{3.16}$$

证明. $P_{UX} v = UX((UX)^T UX)^{-1}(UX)^T v = UX(X^T X)^{-1} X^T U^T v = UP_X U^T v$。因为对于任意 w，$||Uw||_2^2 = w^T U^T Uw = ||w||_2^2$，引理得证。 □

使用这一引理我们有 $||P_{TA} T^* a||_2^2 = ||P_{V_T^T A} U_T^T T^* a||_2^2$。注意 $V_T^T A \in \mathbb{R}^{r \times n}$ 是一个标准高斯矩阵，但是由于 a 的存在我们不能直接将 $V_T^T A$ 替换为某个独立的矩阵变量。这里我们使用跟[4] 中引理 5 的证明类似的思路来解决这一问题。首先因为 $||P_{V_T^T A} U_T^T T^* a||_2^2 = ||U_T^T T^* a||_2^2 - ||P_{(V_T^T A)^\perp} U_T^T T^* a||_2^2$，我们着眼于 $||P_{(V_T^T A)^\perp} U_T^T T^* a||_2^2$ 这一项。让 $S_1 = \mathcal{R}(V_T^T a)$，$S_{-1} = \mathcal{R}(V_T^T A_{:,2:n})$。那么 $\mathcal{R}(V_T^T A)^\perp = S_1^\perp \cap S_{-1}^\perp$。现在我们有

$$\begin{aligned} ||P_{(V_T^T A)^\perp} U_T^T T^* a||_2^2 &= ||P_{S_1^\perp \cap S_{-1}^\perp} P_{S_1^\perp} U_T^T T^* a||_2^2 \\ &= ||P_{S_1^\perp \cap S_{-1}^\perp} u||_2^2 \cdot ||P_{S_1^\perp} U_T^T T^* a||_2^2 \end{aligned} \tag{3.17}$$

其中 $u = \frac{P_{S_1^\perp} U_T^T T^* a}{||P_{S_1^\perp} U_T^T T^* a||_2}$。

由此，S_{-1} 是一个 $r \times (n-1)$ 的标准高斯矩阵的列空间，因此 $S_{-1}^\perp$ 是一个 $\mathbb{R}^r$ 中的 $r - n + 1$ 维的均匀子空间。固定 a，$S_1^\perp$ 是一个固定的 $r - 1$ 维子空间，因此 $S_1^\perp \cap S_{-1}^\perp$ 是 $S_1^\perp$ 中一个 $r - n$ 维的均匀子空间。所以 $||P_{S_1^\perp \cap S_{-1}^\perp} u||_2^2$ 等价于 $X = ||P_{r-n}^{r-1} v||_2^2 = 1 - ||P_{n-1}^{r-1} v||_2^2$，一个随即投影的 2 范数的平方，其中 v 代表 $r - 1$ 维中一个固定的标准基向量。 □

我们现在需要对如下概率寻找下界约束：

$$P\left(\frac{2}{\text{snr}} < ||T^* a||_2 - \sqrt{(1-X)||T^T T^* a||_2^2 + X||P_{Ta} T^* a||_2^2}\right) \tag{3.18}$$

我们可以进一步放缩该式：

$$\begin{aligned} &P\left(\frac{2}{\text{snr}} < ||T^* a||_2 - \sqrt{(1-X)||T^T T^* a||_2^2 + X||P_{Ta} T^* a||_2^2}\right) \\ &\geq P\left(\frac{2}{\text{snr}} < ||T^* a||_2 - \sqrt{||T^* a||_2^2 - X(||T^* a||_2^2 - ||P_{Ta} T^* a||_2^2)}\right) \\ &\geq P\left(X > \frac{4}{\text{snr}} \cdot \frac{||T^* a||_2}{||T^* a||_2^2 - ||P_{Ta} T^* a||_2^2}\right) \end{aligned} \tag{3.19}$$

因此现在我们需要对如下项寻找合适的概率性上界：

$$\frac{||T^* a||_2}{||T^* a||_2^2 - ||P_{Ta} T^* a||_2^2} \tag{3.20}$$

3.3.2 进一步的放缩（满秩情形）

我们分析在 $\mathcal{T}$ 中元素为满秩时的情形，并在第3.3.6节讨论一般情形（即 $\mathcal{T}$ 重元素可为非满秩）。

当 $\mathcal{T}$ 中元素为满秩时，其所有奇异值均为 1，因此它们为正交矩阵。定义

$$d(T,T^*) = 1 - \frac{|<T,T^*>|}{m} \tag{3.21}$$

为一个衡量 T,T^* 之间“距离”的函数。现在我们有如下结论。

引理 11. *在假设2和假设3下，当 $\mathcal{T}$ 中元素为满秩时，我们有对于任意的 $\delta_1,\delta_2>0$，*

$$\frac{||T^*a||_2}{||T^*a||_2^2 - ||P_{Ta}T^*a||_2^2} \le \frac{(1+\delta_2)}{\delta_1\sqrt{m}\cdot d(T,T^*)} \tag{3.22}$$

成立的概率不小于 $1 - Cm\delta_1^{1/2} - 2\exp(-Cm\delta_2^2)$。

证明. 对于分母项，我们有

$$\begin{aligned} ||T^*a||_2^2 - ||P_{Ta}T^*a||_2^2 &= ||a||_2^2 - \frac{(a^TT^TT^*a)^2}{||a||_2^2} \\ &\ge ||a||_2^2 - |a^TT^TT^*a| \end{aligned} \tag{3.23}$$

让 Λ 为 $\frac{T^TT^*+T^{*T}T}{2}$ 的对角特征值矩阵。注意根据我们的假设有 $||\Lambda||_\infty \le 1$。根据高斯向量的旋转不变性，$||a||_2^2 - |a^TT^TT^*a|$ 在分布上与 $||a||_2^2 - |a^T\Lambda a|$ 等价。对于某个正值 t 我们现在约束 $P(||a||_2^2 - |a^T\Lambda a| \le t)$。使用布尔不等式和[4] 中的引理 8，我们有

$$\begin{aligned} &P(||a||_2^2 - |a^T\Lambda a| \le t) \\ &\quad\le P(||a||_2^2 - a^T\Lambda a \le t) + P(||a||_2^2 + a^T\Lambda a \le t) \\ &\quad= P(a^T(I-\Lambda)a \le t) + P(a^T(I+\Lambda)a \le t) \\ &\quad\le \sum_{i\in[m],\Lambda_i\ne 1} P(a_i^2 \le \frac{t}{m-Tr(\Lambda)}) + \sum_{i\in[m],\Lambda_i\ne -1} P(a_i^2 \le \frac{t}{m+Tr(\Lambda)}) \\ &\quad\le 2m\cdot P(a_1^2 \le \frac{t}{m-|Tr(\Lambda)|}) \\ &\quad\le 2m\cdot(\delta\exp(1-\delta))^{1/2} \\ &\quad\le Cm\delta^{1/2} \end{aligned} \tag{3.24}$$

其中 $t = \delta(m - |Tr(\Lambda)|) = \delta m\cdot d(T,T^*)$ 同时 $0<\delta<1$。因此

$$||T^*a||_2^2 - ||P_{Ta}T^*a||_2^2 \ge \delta_1 m\cdot d(T,T^*) \tag{3.25}$$

成立的概率不小于 $1 - Cm\delta_1^{1/2}$。

现在对于分子项 $||T^*a||_2 = ||a||_2$，根据[20] 中的定理 6.3.2 我们有 $||a||_2 \leq \sqrt{m}(1+\delta_2)$ 成立的概率不小于 $1 - 2\exp(-Cm\delta_2^2)$。综合我们对分子项与分母项的约束，引理得证。 □

3.3.3 对随机投影进行概率约束

我们现在约束 $P(X > \frac{4}{\text{snr}} \cdot \frac{(1+\delta_2)}{\delta_1\sqrt{m}d(T,T^*)})$，从式（3.19）继续我们的讨论。使用[4] 中的引理 10，其中设 $\beta = (1-z)\frac{r-1}{n-1}$，在 $\beta > 1$ 时（等价于 $z < \frac{r-n}{r-1}$）我们有

$$\begin{aligned} P(X < z) &\leq (\frac{r-1}{n-1})^{\frac{n-1}{2}} \cdot (\frac{r-1}{r-n})^{\frac{r-n}{2}} \cdot z^{\frac{r-n}{2}} \\ &\leq 2^{r-1} z^{\frac{r-n}{2}} \end{aligned} \tag{3.26}$$

代入 $z = \frac{4}{\text{snr}} \cdot \frac{(1+\delta_2)}{\delta_1\sqrt{m}d(T,T^*)}$，并利用引理9，等式（3.19）和引理11我们可以得到如下引理。

引理 12. *在假设2和假设3下，当 $\mathcal{T}$ 中元素为满秩时，我们有对于任意的 $\delta_1, \delta_2 > 0$，如果*

$$snr > \frac{4(m-1)(1+\delta_2)}{(m-n)\delta_1\sqrt{m} \cdot d(T,T^*)} \tag{3.27}$$

那么 $2||\epsilon||_2 < ||y||_2 - ||P_{TA}y||_2$ 成立的概率至少为

$$1 - Cm\delta_1^{1/2} - 2\exp(-Cm\delta_2^2) - 2^{2m-n-1}(\frac{1+\delta_2}{\delta_1\sqrt{m}d(T,T^*)})^{\frac{m-n}{2}}(\frac{1}{snr})^{\frac{m-n}{2}} \tag{3.28}$$

现在在 $\mathcal{T} \setminus T^*$ 上使用布尔不等式，其中对每个 T 我们都选取相同的 δ_1, δ_2 并结合引理8，我们有

命题 2. *在假设2和假设3下，当 $\mathcal{T}$ 中元素为满秩时，我们有对于任意的 $\delta_1, \delta_2 > 0$，如果*

$$snr > \frac{4(m-1)(1+\delta_2)}{(m-n)\delta_1\sqrt{m} \cdot \min_{T\in\mathcal{T}\setminus T^*} d(T,T^*)} \tag{3.29}$$

那么 $\hat{\tau} \in \mathcal{T}_1$ 的概率至少为

$$\begin{aligned} &1 - |\mathcal{T}|(Cm\delta_1^{1/2} + 2\exp(-Cm\delta_2^2)) \\ &- 2^{2m-n-1}\left(\frac{1+\delta_2}{\delta_1\sqrt{m}}\right)^{\frac{m-n}{2}}\left(\sum_{T\in\mathcal{T}\setminus T^*} d(T,T^*)^{-\frac{m-n}{2}}\right)(\frac{1}{snr})^{\frac{m-n}{2}} \end{aligned} \tag{3.30}$$

3.3.4 约束估测误差

在前一节我们推导出了能够保证 $\hat{T} \in \mathcal{T}_1$ 的概率约束条件，因此现在我们需要在 $\hat{T} \in \mathcal{T}_1$ 的情况下进一步约束估测误差。我们有如下结论。

引理 13. *在假设1，假设2和假设3下，如果 $\hat{T} \in \mathcal{T}_1$，那么*

$$\frac{||\hat{x} - x^*||_2}{||\epsilon||_2} \leq \frac{1}{\sqrt{\hat{r}} - C\sqrt{n}(1+\delta_3)} \tag{3.31}$$

成立的概率至少为 $1 - 2\exp(-n\delta_3^2)$，其中 $\hat{r} = \mathrm{rank}(\hat{T})$。

证明. 由引理7我们有当 $\hat{\tau} \in \mathcal{T}_1$ 时，

$$||\hat{T}A(\hat{x} - x^*)||_2^2 = ||P_{\hat{T}A}\epsilon||_2^2 \tag{3.32}$$

让 $\hat{T}$ 的简奇异值分解为 $U_{\hat{T}}V_{\hat{T}}^T$，其中 $U_{\hat{T}}, V_{\hat{T}} \in \mathbb{R}^{m\times\hat{r}}$。现在 $B = V_{\hat{T}}^T A \in \mathbb{R}^{\hat{r}\times n}$ 是一个标准高斯矩阵。那么 $\hat{T}A = U_{\hat{T}}B$。因此我们有

$$||\hat{x} - x^*||_2^2 \leq \frac{||P_{\hat{T}A}\epsilon||_2^2}{\lambda_{\min}(A^T\hat{T}^T\hat{T}A)} \leq \frac{||\epsilon||_2^2}{\lambda_{\min}(B^TB)} \tag{3.33}$$

所以

$$||\hat{x} - x^*||_2 \leq \frac{||\epsilon||_2}{\sigma_n(B)} \tag{3.34}$$

利用[20] 中的定理 4.6.1，有 $\sigma_n(B) \geq \sqrt{\hat{r}} - C\sqrt{n}(1+\delta_3)$ 成立的概率不小于 $1 - 2\exp(-n\delta_3^2)$。至此综合前述命题得证。 □

3.3.5 主要结论与渐近分析

应用命题2并且应用引理13，其中令 $\hat{r} = m$，我们得到最终的能够在满秩情况下刻画信噪比和估测误差之间关系的结论。

定理 4. *让 $A \in \mathbb{R}^{m\times n}$ 是一个标准高斯矩阵，同时无噪声下同态感知性质成立。假设所有 $\mathcal{T}$ 中的变换为正交变换。那么对于任意的 $\delta_1, \delta_2, \delta_3 \geq 0$，如果*

$$snr = \frac{||x^*||_2}{||\epsilon||_2} > \frac{4(m-1)(1+\delta_2)}{(m-n)\delta_1\sqrt{m}\cdot\min_{T\in\mathcal{T}\setminus T^*} d(T,T^*)} \tag{3.35}$$

那么我们有

$$err = \frac{||\hat{x} - x^*||_2}{||\epsilon||_2} \leq \frac{1}{\sqrt{m} - C\sqrt{n}(1+\delta_3)} \tag{3.36}$$

成立的概率不小于

$$\begin{aligned} &1 - |\mathcal{T}|(Cm\delta_1^{1/2} + 2\exp(-Cm\delta_2^2)) - 2\exp(-n\delta_3^2) \\ &- 2^{2m-n-1}\left(\frac{1+\delta_2}{\delta_1\sqrt{m}}\right)^{\frac{m-n}{2}} \cdot \left(\sum_{T\in\mathcal{T}\setminus T^*} d(T,T^*)^{-\frac{m-n}{2}}\right)\left(\frac{1}{snr}\right)^{\frac{m-n}{2}} \end{aligned} \tag{3.37}$$

让我们进一步对该约束做渐近分析。首先当 m 大于某些绝对常数时，2^{2m-n-1} 可以忽略。举例来说，当 $m > 256$ 时，$\sqrt{m}^{\frac{m-n}{2}} > 2^{2m-n-1}$，因此我们可以替换 $\sqrt{m}$ 为 $C\sqrt{m}$ 并忽略 2^{2m-n-1}。现在对于与 δ_2 相关的项，为了使得 $|\mathcal{T}|\exp(-Cm\delta_2^2)$ 在常数级，我们需要有 $\delta_2 = \Theta(\sqrt{\frac{\log|\mathcal{T}|}{m}})$。为了使 $|\mathcal{T}|Cm\delta_1^{1/2}$ 为常数级，需要 $\frac{1}{\delta_1} = \Theta(m^2|\mathcal{T}|^2)$。最后，$\delta_3$ 相关的项在渐近条件下可以忽略。因此整合上述并代入至（3.35）和（3.37），我们可以看到为了使概率约束渐近趋向于 1 所需要的信噪比为

$$\mathrm{snr} = \Theta\left[m \cdot |\mathcal{T}|^2(\sqrt{m} + \sqrt{\log|\mathcal{T}|}) \cdot \chi(T^*, \mathcal{T}, m, n)\right] \tag{3.38}$$

其中

$$\chi(T^*, \mathcal{T}, m, n) := \max\left(\left(\sum_{T \in \mathcal{T}\setminus T^*} d(T, T^*)^{-\frac{m-n}{2}}\right)^{\frac{2}{m-n}}, \frac{m}{(m-n)\min_{T \in \mathcal{T}\setminus T^*} d(T, T^*)}\right) \tag{3.39}$$

我们看到这一结果与我们对该问题的直觉高度吻合：

- m,$|\mathcal{T}|$ 对信噪比的要求呈正增长，n 对信噪比的要求成负增长。
- 信噪比要求随着集合中 $d(T, T^*)$ 减小而增加，即 $\mathcal{T}$ 中元素越为“接近”，则信噪比要求越高。

在乱序线性回归中，$\mathcal{T}$ 为所有排列矩阵的集合。我们用 Π 表示排列矩阵。固定某个 Π^*，由于满足 $d(\Pi^*, \Pi) = k$ 的 Π 不超过 m^k 个，同时 (3.39) 的第二项明显小于第一项，可以看到 (3.39) 的一个上界为

$$\left(\sum_{2 \le k \le m} m^k (m/k)^{\frac{m-n}{2}}\right)^{\frac{2}{m-n}} \tag{3.40}$$

我们用该上界做出对应的信噪比要求曲线，如图3.1所示。可以看到信噪比要求随着 m/n 的增大而增大，同时在固定 m/n 时随着 m, n 增大而增大。

我们把比较我们的分析与其它同态感知实例中的噪声分析视为未来工作。

3.3.6 对于一般情况的讨论

定理4只能被应用于 $\mathcal{T}$ 中元素为正交矩阵的实例中，例如乱序线性回归和实相位恢复。我们猜想在一般情况下类似的结论可以被推导。回到等式（3.19），我

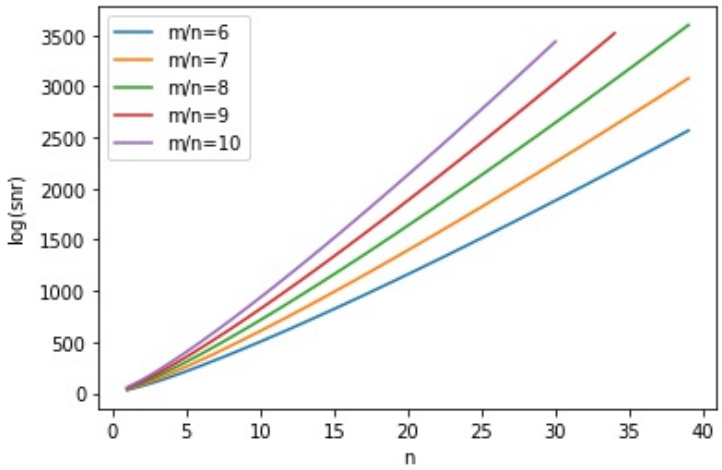

图 3.1 信噪比要求的对数与 n，m/n 的关系曲线

们需要 $||T^*a||_2^2 - ||P_{Ta}T^*a||_2^2$ 的下界约束。假设所有的 T 的秩均为 r。现在我们有

$$\begin{aligned} ||T^*a||_2^2 - ||P_{Ta}T^*a||_2^2 &= ||T^*a||_2^2 - \frac{(a^TT^TT^*a)^2}{||Ta||_2^2} \\ &\geq ||T^*a||_2^2 - \frac{|a^TT^TT^*a| \cdot ||T^*a||_2}{||Ta||_2} \\ &= a^TT^{*T}T^*a - \frac{||T^*a||_2}{||Ta||_2} \cdot |a^TT^TT^*a| \end{aligned} \tag{3.41}$$

利用[20] 中的定理 6.3.2，我们有 $\frac{1-\delta_1}{1+\delta_1} \leq \frac{||T^*a||_2}{||Ta||_2} \leq \frac{1+\delta_1}{1-\delta_1}$ 成立的概率不小于 $1-4\exp(-Cr\delta_1^2)$。因此对于某个正值 t，以概率至少 $1-4\exp(-Cr\delta_1^2)$ 有

$$\begin{aligned} &P(a^TT^{*T}T^*a - \frac{||T^*a||_2}{||Ta||_2} \cdot |a^TT^TT^*a| \leq t) \\ &\leq P(a^TT^{*T}T^*a - \frac{||T^*a||_2}{||Ta||_2} \cdot a^TT^TT^*a \leq t) + P(a^TT^{*T}T^*a + \frac{||T^*a||_2}{||Ta||_2} \cdot a^TT^TT^*a \leq t) \\ &\leq P(a^TT^{*T}T^*a - \frac{1+\delta_1}{1-\delta_1} \cdot a^TT^TT^*a \leq t) + P(a^TT^{*T}T^*a + \frac{1-\delta_1}{1+\delta_1} \cdot a^TT^TT^*a \leq t) \end{aligned} \tag{3.42}$$

这里我们来到了与（3.24）相似的情况，但一个最大的不同在于 $\frac{1+\delta_1}{1-\delta_1}$ 和 $\frac{1-\delta_1}{1+\delta_1}$ 两项的出现。尽管这两项可以在 n 足够大时无限趋近于 1（也因此这两项对于渐近分析其实没有影响），它们永远都不可能等于 1，这也给后续的理论分析带来困难。我们相信这个问题可以被解决，并猜测一个类似于定理4的，可以适用于一般情况的结论可以被推导。我们将这一研究视为未来工作。

第 4 章　结论与展望

我们对同态感知做出两方面的贡献。首先我们将同态感知拓展至输入空间为多个线性子空间并集的情况。这一工作的应用之一是对于一类稀疏信号恢复唯一性的问题给出理论保证。其次我们研究了噪声下的同态感知，并且 1）推导出能够确保较小估测误差的决定性条件; 2）对决定性条件进行了概率分析，并推导出可以刻画信噪比于估测误差之间关系的理论。我们目前的概率分析应用于正交变换的场景（如乱序线性回归和实相位恢复）。我们猜想一个类似的适用于更一般情况的理论可以被推导，并将这一研究视为未来工作。

参考文献

[1] Manolis C. Tsakiris and Liangzu Peng. Homomorphic sensing. In *International Conference on Machine Learning*, 2019.

[2] Jayakrishnan Unnikrishnan, Saeid Haghighatshoar, and Martin Vetterli. Unlabeled sensing with random linear measurements. *IEEE Transactions on Information Theory*, PP(99), 2015.

[3] Daniel J. Hsu, Kevin Shi, and Xiaorui Sun. Linear regression without correspondence. In *Advances in Neural Information Processing Systems*, pages 1531–1540, 2017.

[4] Ashwin Pananjady, Martin J. Wainwright, and Thomas A. Courtade. Linear regression with shuffled data: Statistical and computational limits of permutation recovery. *IEEE Transactions on Information Theory*, 64(5):3286–3300, 2017.

[5] Abubakar Abid and James Zou. A stochastic expectation-maximization approach to shuffled linear regression. In *2018 56th Annual Allerton Conference on Communication, Control, and Computing (Allerton)*, pages 470–477. IEEE, 2018.

[6] Manolis C. Tsakiris, Liangzu Peng, Aldo Conca, Laurent Kneip, Yuanming Shi, and Hay-oung Choi. An algebraic-geometric approach to shuffled linear regression. *arXiv preprint arXiv:1810.05440*, 2018.

[7] Wei Lian, Lei Zhang, and Ming-Hsuan Yang. An efficient globally optimal algorithm for asymmetric point matching. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, pages 1–1, 2016.

[8] Philip David, Daniel Dementhon, Ramani Duraiswami, and Hanan Samet. Softposit: Simul-taneous pose and correspondence determination. *International Journal of Computer Vision*, 59(3):259–284, 2004.

[9] Manuel Marques, Marko Stosic, and Joa Costeira. Subspace matching: Unique solution to point matching with geometric constraints. In *IEEE International Conference on Computer Vision*, 2009.

[10] Aubrey B. Poore and Sabino Gadaleta. Some assignment problems arising from multiple target tracking. *Mathematical and Computer Modelling*, 43(9):1074–1091, 2006.

[11] Partha Lahiri and Michael D. Larsen. Regression analysis with linked data. *Journal of the American statistical association*, 100(469):222–230, 2005.

[12] Xu Shi, Xiaoou Li, and Tianxi Cai. Spherical regression under mismatch corruption with application to automated knowledge translation. *Journal of the American Statistical Association*:1–28, 2020.

[13] Fusheng Lv and Wenchang Sun. Real phase retrieval from unordered partial frame coefficients. *Advances in Computational Mathematics*, 2017.

[14] Jason M. Klusowski, Dana Yang, and William D. Brinda. Estimating the coefficients of a mixture of two linear regressions by expectation maximization. *IEEE Transactions on Information Theory*, 65(6):3515–3524, 2019.

[15] Xiaodong Li and Vladislav Voroninski. Sparse signal recovery from quadratic measurements via convex programming. *SIAM Journal on Mathematical Analysis*, 45(5):3019–3033, 2013.

[16] Henrik Ohlsson and Yonina C. Eldar. On conditions for uniqueness in sparse phase retrieval. *IEEE International Conference on Acoustics Speech & Signal Processing*, 2013.

[17] Martin Slawski and Emanuel Ben-David. Linear regression with sparsely permuted data. *Electronic Journal of Statistics*, 2017.

[18] Steven Roman. *Advanced linear algebra*. Springer, 2005.

[19] Joe Harris. *Algebraic geometry: a first course*. Springer-Verlag, 1992.

[20] Roman Vershynin. *High-Dimensional Probability: An Introduction with Applications in Data Science*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2018.

致　谢

感谢彭良祖发现并分享噪声下同态感知的决定性条件，以及许多让我非常受益的讨论和见解。感谢李佳欣在我在校隔离期间不辞劳苦递送可口的饭菜，以及一直以来的爱与鼓励。感谢父母对我的关心与支持。感谢一路走来所有帮助过我的人。